



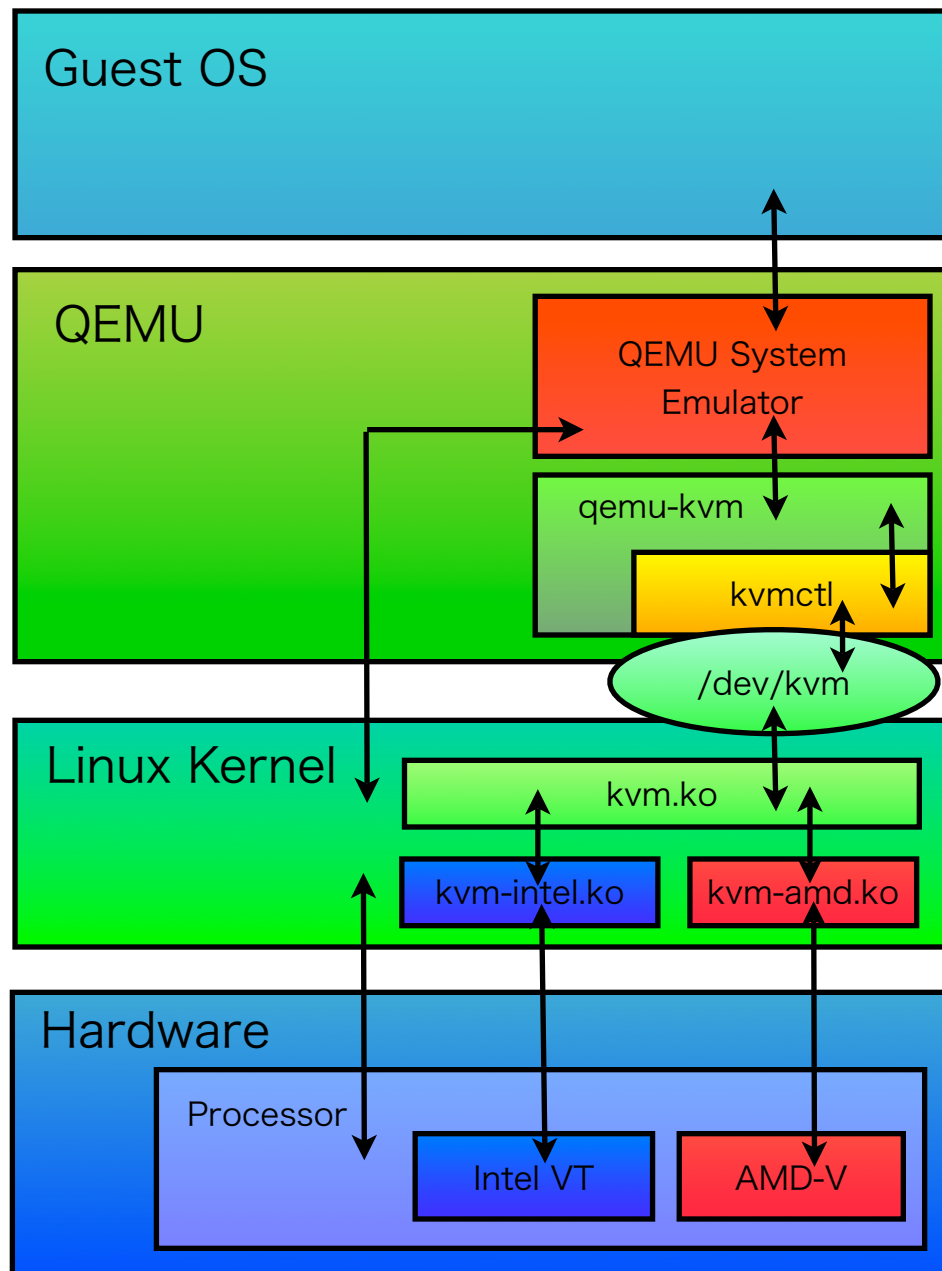
# 濃いバナ KVMの仕組み

仮想化友の会

平 初 <htaira@pantora.net>



# KVMの仕組み



## KVMはQEMUの拡張機能

- KVM拡張機能(qemu-kvm.c)が同時にコンパイル
- カーネル空間で動くコンポーネントとユーザ空間で動くコンポーネントが存在

## 2種類のカーネルモジュール

- Intel VT(Intel Virtualization Technology)向けのカーネルモジュール → kvm-intel.ko
- AMD-V(AMD Virtualization)向けのカーネルモジュール → kvm-amd.ko

## KVMとQEMU間の通信方法

- KVMキャラクタデバイス(/dev/kvm)を経由
- 操作はmmap()、ioctl()などの関数
- 操作はユーザ空間で動くライブラリ(kvmctl.c)を経由し行うこと

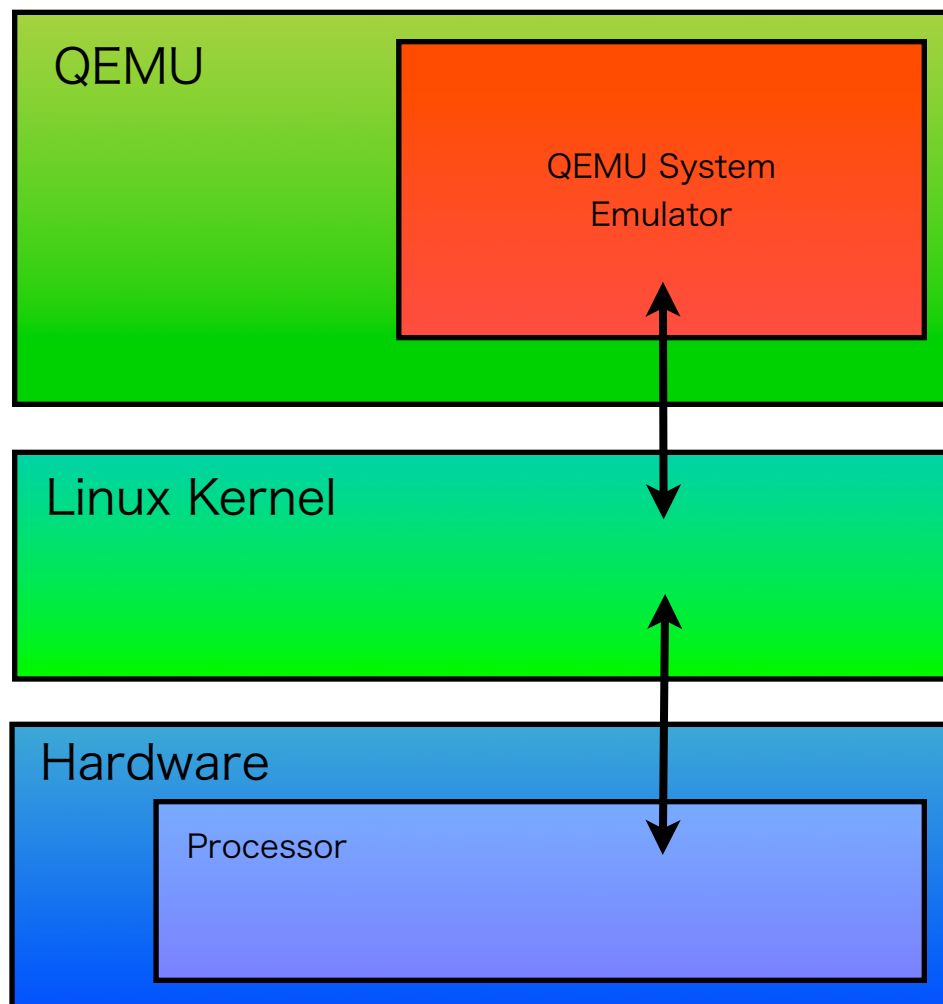
## KVMが有効な場合

- /dev/kvmが存在する
- kvm\_allowed == 1 (QEMUの中の変数)

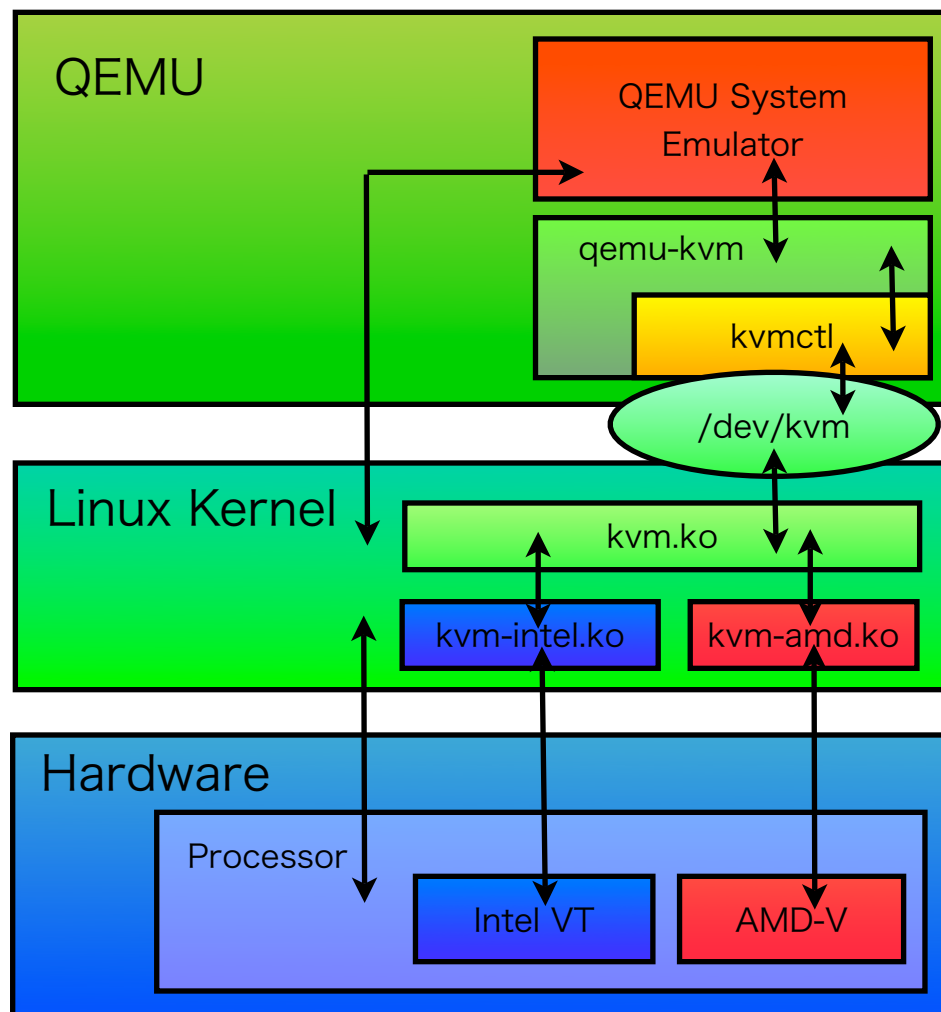


# QEMUとKVM比較

## QEMUの仕組み



## KVMの仕組み





## ソースコードのディレクトリ構造 1/2

- kvm-15/
  - kvm ... QEMUのラップスクリプト(Python)
- kvm-15/qemu/ ... KVMに対応したQEMU
  - vl.c ... QEMU System Emulatorのコアコンポーネント
  - qemu-kvm.c ... QEMUのKVM拡張機能に関する関数が含まれる
  - qemu-kvm.h ... QEMUのKVM拡張機能に関する関数のヘッダーファイル
  - cpu-exec.c ... QEMUのゲストOSのCPU命令を解釈する関数が含まれる
- kvm-15/kernel/ ... KVMカーネルモジュール
  - kvm\_main.c ... QEMUのKVM拡張機能に関する関数のヘッダーファイル
  - x86\_emulate.c ... x86リアルモードをエミュレーションするコンポーネント
  - kvm\_vmx.c ... Intel VT用のカーネルモジュール
  - vmx.c ... Intel VT使用時にIntel VT用命令を処理するコンポーネント
  - mmu.c ... Intel VTの時にメモリ管理を行うコンポーネント
  - kvm\_svm.c ... AMD-V用のカーネルモジュール
  - svm.c ... AMD-V使用時にAMD-V用命令を処理するコンポーネント



## ソースコードのディレクトリ構造 2/2

- kvm-15/user/ ... ユーザ空間で動くコンポーネント
  - kvmctl.c ... KVMキャラクタデバイス(/dev/kvm)と通信するコンポーネント
  - main.c ... KVM機能を試すテストアプリケーション
  - test/ ... ほとんどアセンブラで書かれた小さなOSが入っています。
- kvm-15/scripts/ ... KVMの周辺スクリプト
- kvm-15/drivers/ ... ゲストOS向けパラバーチャルドライバ
  - hypercall.c ... Linux向けパラバーチャルドライバ  
(SCSIドライバやNICドライバが今後このドライバを経由するはず)



## KVMの起動

```
# kvm --image ./hda.img
```

kvmスクリプト(kvm-15/kvm)

```
117 vendor_module = {
118     'GenuineIntel': 'kvm-intel',
119     'AuthenticAMD': 'kvm-amd',
120 }[vendor()]
121
122 if options.kvm and options.reload:
123     for module in [vendor_module, 'kvm']:
124         remove_module(module)
125     for module in ['kvm', vendor_module]:
126         insert_module(module)
127     for i in range(5):
128         if os.access('/dev/kvm', os.F_OK):
129             break
130     time.sleep(0.1 + 0.2 * i)
131     if not os.access('/dev/kvm', os.F_OK):
132         print '/dev/kvm not present'
```

```
110 def vendor():
111     for x in file('/proc/cpuinfo').readlines():
112         m = re.match(r'vendor_id[ \t]*: *([a-zA-Z]+)', x)
113         if m:
114             return m.group(1)
115     return unknown
```

1-1 Intel用カーネルモジュールとAMD用カーネルモジュール  
のどちらを読み込むかチェックする。

(/proc/cpuinfoの情報より自動判別)

1-2 最適なカーネルモジュールが読み込まれる。

1-3 KVMキャラクタデバイス(/dev/kvm)があるか  
チェックする。

1-4 CPUが64bitアーキテクチャがチェックし、最適なQEMUを  
起動する。

(Pythonのplatformライブラリによりカーネルの種類は自動判別)



## KVMの起動

kvmスクリプト (kvm-15/kvm)

1-4 CPUが64bitアーキテクチャがチェックし、  
最適なQEMUを起動する。

(Pythonのplatformライブラリによりカーネルの種類は自動判別)

```
146 import platform
147 arch = platform.machine()
148 # check 32-bit userspace on 64-bit kernel
149 if platform.architecture()[0] == '32bit':
150     arch = 'i386'
151
152 if arch == 'x86_64':
153     cmd = 'qemu-system-' + arch
154 else:
155     cmd = 'qemu'
156
157 local_cmd = 'qemu/' + arch + '-softmmu/' + cmd
158 if os.access(local_cmd, os.F_OK):
159     cmd = local_cmd
160 else:
161     cmd = '/usr/bin/kvm'
162
163 qemu_args = (cmd, '-boot', bootdisk,
164             '-hda', disk, '-m', '384',
165             '-serial', 'file:/tmp/serial.log',
166             '-usbdevice', 'tablet'
167             )
```



## KVMの起動

2-1 KVMを使うかどうかチェックされる。

2-2 KVMを使う場合(`kvm_allowed == 1`)、KVMを初期化する関数 `kvm_qemu_init()` が呼ばれる。

`main()` in `kvm-15/qemu/vl.c`

```
7338     signal(SIGFPE, SIG_IGN);
7339 }
7340 #endif
7341
7342 #if USE_KVM
7343     if (kvm_allowed) {
7344         if (kvm_qemu_init() < 0) {
7345             fprintf(stderr, "Could not initialize KVM, will disable KVM support\n");
7346             kvm_allowed = 0;
7347         }
7348     }
7349 #endif
```

```
653     .pre_kvm_run = pre_kvm_run,
654 };
655
656 int kvm_qemu_init()
657 {
658     /* Try to initialize kvm */
659     kvm_context = kvm_init(&qemu_kvm_ops, saved_env);
660     if (!kvm_context) {
661         return -1;
662     }
663
664     return 0;
665 }
666
667 int kvm_qemu_create_context(void)
668 {
```

`kvm_qemu_init()`  
in `kvm-15/qemu/qemu-kvm.c`





## KVMの起動

kvm\_qemu\_init()

in kvm-15/qemu/qemu-kvm.c

```
653 .pre_kvm_run = pre_kvm_run,  
654 };  
655  
656 int kvm_qemu_init()  
657 {  
658     /* Try to initialize kvm */  
659     kvm_context = kvm_init(&qemu_kvm_ops, saved_env);  
660     if (!kvm_context) {  
661         return -1;  
662     }  
663     return 0;  
664 }  
665  
666 int kvm_qemu_create_context(void)  
667 {  
668
```

3-1 kvm\_init()が呼ばれる。

kvm\_init()

in kvm-15/user/kvmctl.c

```
178 kvm_context_t kvm_init(struct kvm_callbacks *callbacks,  
179                        void *opaque)  
180 {  
181     int fd;  
182     kvm_context_t kvm;  
183     int r;  
184  
185     fd = open("/dev/kvm", O_RDWR);  
186     if (fd == -1) {  
187         perror("open /dev/kvm");  
188         return NULL;  
189     }  
190     r = ioctl(fd, KVM_GET_API_VERSION, 0);  
191     if (r == -1) {  
192         fprintf(stderr, "kvm kernel version too old\n");  
193         goto out_close;  
194     }  
195     if (r < EXPECTED_KVM_API_VERSION) {  
196         fprintf(stderr, "kvm kernel version too old\n");  
197         goto out_close;  
198     }  
199     if (r > EXPECTED_KVM_API_VERSION) {  
200         fprintf(stderr, "kvm userspace version too old\n");  
201         goto out_close;  
202     }  
203     kvm = malloc(sizeof(*kvm));  
204     kvm->fd = fd;  
205     kvm->vm_fd = -1;  
206     kvm->callbacks = callbacks;  
207     kvm->opaque = opaque;  
208     kvm->dirty_pages_log_all = 0;  
209     memset(&kvm->mem_regions, 0, sizeof(kvm->mem_regions));  
210  
211     return kvm;  
212 out_close:  
213     close(fd);  
214     return NULL;  
215 }
```



## KVMの起動

kvm\_init()

in kvm-15/user/kvmctl.c

```
178 kvm_context_t kvm_init(struct kvm_callbacks *callbacks,
179                        void *opaque)
180 {
181     int fd;
182     kvm_context_t kvm;
183     int r;
184
185     fd = open("/dev/kvm", O_RDWR);
186     if (fd == -1) {
187         perror("open /dev/kvm");
188         return NULL;
189     }
190     r = ioctl(fd, KVM_GET_API_VERSION, 0);
191     if (r == -1) {
192         fprintf(stderr, "kvm kernel version too old\n");
193         goto out_close;
194     }
195     if (r < EXPECTED_KVM_API_VERSION) {
196         fprintf(stderr, "kvm kernel version too old\n");
197         goto out_close;
198     }
199     if (r > EXPECTED_KVM_API_VERSION) {
200         fprintf(stderr, "kvm userspace version too old\n");
201         goto out_close;
202     }
203     kvm = malloc(sizeof(*kvm));
204     kvm->fd = fd;
205     kvm->vm_fd = -1;
206     kvm->callbacks = callbacks;
207     kvm->opaque = opaque;
208     kvm->dirty_pages_log_all = 0;
209     memset(&kvm->mem_regions, 0, sizeof(kvm->mem_regions));
210
211     return kvm;
212 out_close:
213     close(fd);
214     return NULL;
215 }
```

4-1 KVMキャラクタデバイス(/dev/kvm)がオープンされる。

4-2 KVMのAPIバージョン確認が行われる。


ioctl(fd, KVM\_GET\_API\_VERSION, 0);

kvm\_dev\_ioctl()

in kvm-15/kernel/kvm\_main.c

```
2247 static long kvm_dev_ioctl(struct file *filp,
2248                          unsigned int ioctl, unsigned long arg)
2249 {
2250     void __user *argp = (void __user *)arg;
2251     int r = -EINVAL;
2252
2253     switch (ioctl) {
2254     case KVM_GET_API_VERSION:
2255         r = KVM_API_VERSION;
2256         break;
2257     case KVM_CREATE_VM:
2258         r = kvm_dev_ioctl_create_vm();
2259         break;
2260     case KVM_GET_MSR_INDEX_LIST: {
2261         struct kvm_msr_list *user_msr_list = argp;
2262         default:
2263             ;
2264     }
2265     }
2266     return r;
2267 }
```

kvm\_context\_t 構造体





## KVMの起動

5-1 switch文でKVMのハイパーコールが分岐される。

5-2 KVMのAPIバージョン(KVM\_API\_VERSION)を返す。

kvm\_dev\_ioctl()

in kvm-15/kernel/kvm\_main.c

/dev/kvm

```
2247 static long kvm_dev_ioctl(struct file *filp,  
2248                          unsigned int ioctl, unsigned long arg)  
2249 {  
2250     void __user *argp = (void __user *)arg;  
2251     int r = -EINVAL;  
2252  
2253     switch (ioctl) {  
2254     case KVM_GET_API_VERSION:  
2255         r = KVM_API_VERSION;  
2256         break;  
2257     case KVM_CREATE_VM:  
2258         r = kvm_dev_ioctl_create_vm();  
2259         break;  
2260     case KVM_GET_MSR_INDEX_LIST: {  
2261         struct kvm_msr_list user_msr_list = argp;  
2262         out:  
2290         return r;  
2291     }  
2292 }
```



## KVMの起動

kvm\_init()

in kvm-15/user/kvmctl.c

4-3 kvm\_context\_t 構造体が作られ初期化される。

```
178 kvm_context_t kvm_init(struct kvm_callbacks *callbacks,
179                         void *opaque)
180 {
181     int fd;
182     kvm_context_t kvm;
183     int r;
184
185     fd = open("/dev/kvm", O_RDWR);
186     if (fd == -1) {
187         perror("open /dev/kvm");
188         return NULL;
189     }
190     r = ioctl(fd, KVM_GET_API_VERSION, 0);
191     if (r == -1) {
192         fprintf(stderr, "kvm kernel version too old\n");
193         goto out_close;
194     }
195     if (r < EXPECTED_KVM_API_VERSION) {
196         fprintf(stderr, "kvm kernel version too old\n");
197         goto out_close;
198     }
199     if (r > EXPECTED_KVM_API_VERSION) {
200         fprintf(stderr, "kvm userspace version too old\n");
201         goto out_close;
202     }
203     kvm = malloc(sizeof(*kvm));
204     kvm->fd = fd;
205     kvm->vm_fd = -1;
206     kvm->callbacks = callbacks;
207     kvm->opaque = opaque;
208     kvm->dirty_pages_log_all = 0;
209     memset(&kvm->mem_regions, 0, sizeof(kvm->mem_regions));
210
211     return kvm;
212 out_close:
213     close(fd);
214     return NULL;
215 }
```



## KVMの起動

main() in kvm-15/qemu/vl.c

```
7431 #if USE_KVM
7432 /* Initialize kvm */
7433 if (kvm_allowed) {
7434     phys_ram_size += KVM_EXTRA_PAGES * 4096;
7435     if (kvm_qemu_create_context() < 0) {
7436         fprintf(stderr, "Could not create KVM context\n");
7437         exit(1);
7438     }
7439 } else {
```

2-3 KVM拡張ページ空間(KVM\_EXTRA\_PAGES)を考慮し、  
必要な物理メモリサイズ(phys\_ram\_size)を計算する。

2-4 kvm\_qemu\_create\_context()を呼び出す。

kvm\_qemu\_create\_context()  
in kvm-15/qemu/qemu-kvm.c

```
667 int kvm_qemu_create_context(void)
668 {
669     int i;
670
671     if (kvm_create(kvm_context, phys_ram_size, (void**)
672 &phys_ram_base) < 0) {
673         kvm_qemu_destroy();
674         return -1;
675     }
676     kvm_msr_list = kvm_get_msr_list(kvm_context);
677     if (!kvm_msr_list) {
678         kvm_qemu_destroy();
679         return -1;
680     }
681     for (i = 0; i < kvm_msr_list->nmsrs; ++i)
682         if (kvm_msr_list->indices[i] == MSR_STAR)
683             kvm_has_msr_star = 1;
684     return 0;
685 }
```



## KVMの起動

kvm\_qemu\_create\_context()  
in kvm-15/qemu/qemu-kvm.c

```
667 int kvm_qemu_create_context(void)
668 {
669     int i;
670
671     if (kvm_create(kvm_context, phys_ram_size, (void**)
672 &phys_ram_base) < 0) {
673         kvm_qemu_destroy();
674         return -1;
675     }
676     kvm_msr_list = kvm_get_msr_list(kvm_context);
677     if (!kvm_msr_list) {
678         kvm_qemu_destroy();
679         return -1;
680     }
681     for (i = 0; i < kvm_msr_list->nmsrs; ++i)
682         if (kvm_msr_list->indices[i] == MSR_STAR)
683             kvm_has_msr_star = 1;
684     return 0;
}
```

3-2 kvm\_create()を呼び出す。

kvm\_create\_context()  
in kvm-15/user/kvmctl.c

```
227 int kvm_create(kvm_context_t kvm, unsigned long memory, void **vm_mem)
228 {
229     unsigned long dosmem = 0xa0000;
230     unsigned long exmem = 0xc0000;
231     int fd = kvm->fd;
232     int r;
233     struct kvm_memory_region low_memory = {
234         .slot = 3,
235         .memory_size = memory < dosmem ? memory : dosmem,
236         .guest_phys_addr = 0,
237     };
238     struct kvm_memory_region extended_memory = {
239         .slot = 0,
240         .memory_size = memory < exmem ? 0 : memory - exmem,
241         .guest_phys_addr = exmem,
242     };
243
244     kvm->vcpu_fd[0] = -1;
245
246     fd = ioctl(fd, KVM_CREATE_VM, 0);
247     if (fd == -1) {
248         fprintf(stderr, "kvm_create_vm: %m\n");
249         return -1;
250     }
251     kvm->vm_fd = fd;
252     if (ioctl(fd, KVM_CREATE_VCPU, 0),
253         if (r == -1) {
254             fprintf(stderr, "kvm_create_vcpu: %m\n");
255             return -1;
256         }
257     )
258     kvm->vcpu_fd[0] = r;
259     return 0;
}
```





## KVMの起動

kvm\_create\_context()

in kvm-15/user/kvmctl.c

```
227 int kvm_create(kvm_context_t kvm, unsigned long memory, void **vm_mem)
228 {
229     unsigned long dosmem = 0xa0000;
230     unsigned long exmem = 0xc0000;
231     int fd = kvm->fd;
232     int r;
233     struct kvm_memory_region low_memory = {
234         .slot = 3,
235         .memory_size = memory < dosmem ? memory : dosmem,
236         .guest_phys_addr = 0,
237     };
238     struct kvm_memory_region extended_memory = {
239         .slot = 0,
240         .memory_size = memory < exmem ? 0 : memory - exmem,
241         .guest_phys_addr = exmem,
242     };
243
244     kvm->vcpu_fd[0] = -1;
245
246     fd = ioctl(fd, KVM_CREATE_VM, 0);
247     if (fd == -1) {
248         fprintf(stderr, "kvm_create_vm: %m\n");
249         return -1;
250     }
251     kvm->vm_fd = fd;
252     r = ioctl(fd, KVM_CREATE_VCPU, 0);
253     if (r == -1) {
254         fprintf(stderr, "kvm_create_vcpu: %m\n");
255         return -1;
256     }
257     kvm->vcpu_fd[0] = r;
258     return 0;
259 }
```

4-4 仮想マシン作成が作成される。

ioctl(fd, KVM\_CREATE\_VM, 0);

kvm\_dev\_ioctl()

in kvm-15/kernel/kvm\_main.c

```
2247 static long kvm_dev_ioctl(struct file *filp,
2248                          unsigned int ioctl, unsigned long arg)
2249 {
2250     void __user *argp = (void __user *)arg;
2251     int r = -EINVAL;
2252
2253     switch (ioctl) {
2254     case KVM_GET_API_VERSION:
2255         r = KVM_API_VERSION;
2256         break;
2257     case KVM_CREATE_VM:
2258         r = kvm_dev_ioctl_create_vm();
2259         break;
2260     case KVM_GET_MSR_INDEX_LIST: {
2261         struct kvm_msr_list *user_msr_list = argp;
2262         default:
2263             ;
2264     }
2265     out:
2266     return r;
2267 }
```



5-3 switch文でKVMのハイパーコールが分岐される。

5-4 kvm\_dev\_ioctl\_create\_vm()が呼ばれる。